



**Alunos:** Luisa Helena Bartocci Liboni  
Rodrigo de Toledo Caropreso

**Data de Entrega:** 18/06/2012

## **Redes Neurais Artificiais** (Prof. Ivan Nunes da Silva)

### **EPC-11**

A previsão de potência elétrica é de suma importância para o planejamento operacional de um sistema de energia elétrica. A programação da manutenção do sistema, o planejamento de sua expansão e a análise de despacho é normalmente executado levando-se em consideração a potência elétrica prevista para o respectivo sistema.

A previsão para um dia específico pode ser efetuada levando-se em conta apenas a potência medida nas primeiras horas do dia. Baseado nessas informações, por intermédio da classificação de curvas, é possível traçar o perfil da potência que será necessária para todas as outras horas do dia.

Na tabela abaixo fornece-se a potência medida em 16 dias e que foram agrupadas em 4 classes (perfis) de demanda.

<b>Amostra</b>	<b>7 horas</b>	<b>8 horas</b>	<b>9 horas</b>	<b>10 horas</b>	<b>11 horas</b>	<b>12 horas</b>	<b>Classe</b>
1	2.3976	1.5328	1.9044	1.1937	2.4184	1.8649	1
2	2.3936	1.4804	1.9907	1.2732	2.2719	1.8110	1
3	2.2880	1.4585	1.9867	1.2451	2.3389	1.8099	1
4	2.2904	1.4766	1.8876	1.2706	2.2966	1.7744	1
5	1.1201	0.0587	1.3154	5.3783	3.1849	2.4276	2
6	0.9913	0.1524	1.2700	5.3808	3.0714	2.3331	2
7	1.0915	0.1881	1.1387	5.3701	3.2561	2.3383	2
8	1.0535	0.1229	1.2743	5.3226	3.0950	2.3193	2
9	1.4871	2.3448	0.9918	2.3160	1.6783	5.0850	3
10	1.3312	2.2553	0.9618	2.4702	1.7272	5.0645	3
11	1.3646	2.2945	1.0562	2.4763	1.8051	5.1470	3
12	1.4392	2.2296	1.1278	2.4230	1.7259	5.0876	3
13	2.9364	1.5233	4.6109	1.3160	4.2700	6.8749	4
14	2.9034	1.4640	4.6061	1.4598	4.2912	6.9142	4
15	3.0181	1.4918	4.7051	1.3521	4.2623	6.7966	4
16	2.9374	1.4896	4.7219	1.3977	4.1863	6.8336	4

Assim, implementar e treinar uma LVQ-1 que detecte as possíveis similaridades e regularidades entre todos os vetores pertencentes a cada uma das classes, objetivando-se a classificação futura de perfis de potência de outros dias (amostras). Considere para as simulações uma taxa de aprendizagem  $\eta = 0.05$ .



Após o treinamento da rede, utilize-a para a classificação do perfil de potência para os dias apresentados na tabela a seguir.

**Dados de Teste**

Dia	7 horas	8 horas	9 horas	10 horas	11 horas	12 horas	Classe
1	2.9817	1.5656	4.8391	1.4311	4.1916	6.9718	4
2	1.5537	2.2615	1.3169	2.5873	1.7570	5.0958	3
3	1.2240	0.2445	1.3595	5.4192	3.2027	2.5675	2
4	2.5828	1.5146	2.1119	1.2859	2.3414	1.8695	1
5	2.4168	1.4857	1.8959	1.3013	2.4500	1.7868	1
6	1.0604	0.2276	1.2806	5.4732	3.2133	2.4839	2
7	1.5246	2.4254	1.1353	2.5325	1.7569	5.2640	3
8	3.0565	1.6259	4.7743	1.3654	4.2904	6.9808	4

**Código -Fonte**

```
%a uma classe de dados)
w( :, 1 ) = x( :, 1 );
w( :, 2 ) = x( :, 5 );
w( :, 3 ) = x( :, 9 );
w( :, 4 ) = x( :, 13 );

Carrega_Tabela_Treino;

eta = 0.05;
epoca = 0;
x0 = [DB_X1 DB_X2 DB_X3 DB_X4 DB_X5 stop = 0;
DB_X6]';
d = [DB_D]'; %saidas para treinamento supervisionado
w_anterior = w;
maior_mudanca_anterior = 0;
N1 = 4; %neuronios (na LVQ o numero de neurons == quantidade de classes)
N = 6; %entradas
while(~stop)
    eptron = 1e-4;
    for k=1:N_Amostras
        for j = 1: N1
            D(j, k) =
            sqrt( sum( ( x( :, k ) - w( :, j ) ).^2 ) );
        end;
        [value, winner] = min(D(:, k)); %menor distancia, determina o vencedor
    end;

%Normaliza o vetor de entrada
for k=1:N_Amostras
    x( :, k ) = x0( :, k ) /
    norm(x0( :, k ));
end;

%Inicializacao da matriz de pesos
(cada vetor ou neuron deve ser associado
%Atualiza pesos do vencedor
```



```

        if( winner == d(k) ) %vencedor end;
pertence a classe do treinamento ->
aproxima ele do cluster

        w( :, winner ) = w( :,
winner ) + eta * ( x( :, k ) - w( :,
winner ) );
disp 'Fim do Treinamento: Numero de
Epocas'

        else %vencedor NAO pertence a epoca
classe do treinamento -> afasta ele do
cluster
pause

        w( :, winner ) = w( :,
winner ) - eta * ( x( :, k ) - w( :,
winner ) );
%OPERACAO
Carrega_Tabela_Operacao;
xOp = [DB_X1 DB_X2 DB_X3 DB_X4 DB_X5
DB_X6]';

        %Normaliza

        w( :, winner ) = w( :, winner
) / norm( w( :, winner ) );
N_Amostras = length(DB_X1);

        end;
%Normaliza o vetor de entrada

        epoca = epoca + 1;
for k=1:N_Amostras

            x( :, k ) = xOp( :, k ) /
norm(xOp( :, k ));

        %Criterio de parada

        %
        maior_mudanca_atual = end;
max(max(abs(w-w_anterior)));

        w_change = w-w_anterior;
%Verificação
for k=1:N_Amostras
    for j = 1: N1
        D(j, k) = sqrt( sum( ( x( :, k
) - w( :, j ) ).^2 ) );
    end;

        norma(hh) = norm( w_change( :,
hh ) ); %calcula a norma de cada
coluna

        end;

        maior_mudanca_atual = [value, winner] = min(D(:, k));
max( norma ); %norm(max(abs((w- %menor distancia, determina o vencedor
w_anterior)), [],2));

        maior_mudanca_atual
disp( sprintf( 'Neuronio vencedor
(classe): %d', winner ) );
        if( maior_mudanca_atual < epsilon )
%|| ( maior_mudanca_atual - end;
maior_mudanca_anterior ) < epsilon )

            stop = 1;

        end;

        [N_Amostra DB_X1 DB_X2 DB_X3 DB_X4
DB_X5 DB_X6 DB_D] =
%
textread( 'Dados_Treino.dat', '%d %f
%f %f %f %f %d', 'headerlines', 1);

%
        maior_mudanca_anterior =
maior_mudanca_atual;

        w_anterior = w;

        [N_Amostra DB_X1 DB_X2 DB_X3 DB_X4
DB_X5 DB_X6] =
textread( 'Dados_Operacao.dat', '%d %f
%f %f %f %f %f', 'headerlines', 1);

```