

## Redes neurais artificiais e classificação de padrões

### 1. O problema do OU-exclusivo

- considere os pontos  $(0,0)$ ,  $(0,1)$ ,  $(1,0)$  e  $(1,1)$  no plano  $\mathbb{R}^2$ , conforme apresentado na figura 1. O objetivo é determinar uma rede com duas entradas  $\mathbf{x}_i \in \{0,1\}$  ( $i=1,2$ ), e uma saída  $\mathbf{y} \in \{0,1\}$  de maneira que:
 
$$\begin{cases} (\mathbf{x}_1, \mathbf{x}_2) = (0,0) \text{ ou } (1,1) \Rightarrow \mathbf{y} = 0 \\ (\mathbf{x}_1, \mathbf{x}_2) = (1,0) \text{ ou } (0,1) \Rightarrow \mathbf{y} = 1 \end{cases}$$




Figura 1 - O problema do OU-exclusivo

- inicialmente será analisado o comportamento de um neurônio tipo perceptron (veja figura 2) no processo de solução do problema exposto acima. A saída  $\mathbf{y}$  pode ser representada na forma:

$$\mathbf{y} = \mathbf{g}(\mathbf{w}_1\mathbf{x}_1 + \mathbf{w}_2\mathbf{x}_2 + \mathbf{w}_0) \quad \text{onde} \quad \begin{cases} \mathbf{g}(\mathbf{u}) = 1 & \text{se } \mathbf{u} \geq 0 \\ \mathbf{g}(\mathbf{u}) = 0 & \text{se } \mathbf{u} < 0 \end{cases}$$




Figura 2 – Neurônio tipo perceptron, com duas entradas (mais a polarização)

- para qualquer valor dos parâmetros  $\mathbf{w}_0$ ,  $\mathbf{w}_1$  e  $\mathbf{w}_2$ , a função  $\mathbf{g}(\mathbf{u})$  separa o espaço de entrada em duas regiões, sendo que a curva de separação é uma linha reta.

- no problema do OU-exclusivo (figura 1), pode-se constatar que não existe uma única linha reta divisória de forma que os pontos (0,0) e (1,1) se posicionem de um lado enquanto que (0,1) e (1,0) permaneçam do outro lado da linha.
- logo, pode-se imediatamente concluir que um neurônio tipo perceptron não apresenta grau de liberdade suficiente para resolver o problema proposto, o que foi corretamente constatado por Minsky & Papert, em 1969.
- no entanto, esses autores também acreditavam que não havia razão para supor que redes multi-camadas pudessem conduzir a uma solução para o problema proposto. Esta hipótese só foi definitivamente rejeitada com o desenvolvimento do algoritmo de retro-propagação (*back-propagation*), já nos anos 80, o qual permite o ajuste automático de pesos para redes neurais multi-camadas, arquitetura necessária para a realização de mapeamentos não-lineares, como será verificado mais adiante.

- considere o problema de mapeamento de uma rede neural tipo perceptron, com uma camada intermediária (veja figura 3), aplicado ao problema do OU-exclusivo.

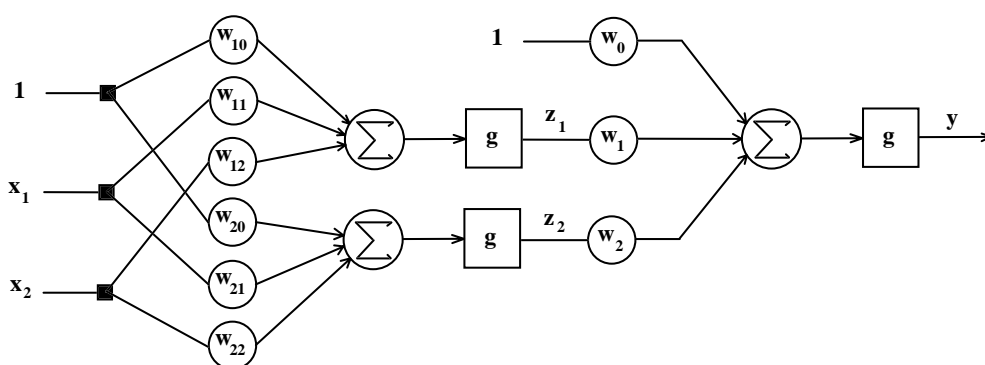


Figura 3 - Perceptron de três camadas (uma camada intermediária)

- a camada de entrada fornece um vetor de entrada  $(x_1, x_2)$  para a camada intermediária, enquanto que a camada intermediária produz duas saídas  $z_1 = \text{sgn}(w_{10} + w_{11}x_1 + w_{12}x_2)$  e  $z_2 = \text{sgn}(w_{20} + w_{21}x_1 + w_{22}x_2)$ . Na camada de saída, o sinal de saída da rede neural é dado por  $y = \text{sgn}(w_0 + w_1z_1 + w_2z_2)$ .

- surge uma questão: existem parâmetros  $w_{ij}$  ( $i=1,2$ ;  $j=0,1,2$ ) e  $w_k$  ( $k = 0,1,2$ ) tais que  $y = 0$  para as entradas (0,0) e (1,1) e  $y = 1$  para as entradas (1,0) e (0,1)?
- as saídas da primeira camada ( $z_1$  e  $z_2$ ) podem ser consideradas como variáveis intermediárias utilizadas na geração da saída  $y$ .
- do que já foi visto a respeito de um neurônio tipo perceptron, segue-se que existem pesos  $w_{1j}$  ( $j=0,1,2$ ) tais que (veja curva de separação  $L_1$  na figura 4(a)):

(0,1) produza  $z_1 = 1$   
(0,0),(1,0),(1,1) produza  $z_1 = 0$ .

- de forma similar, existem pesos  $w_{2j}$  ( $j=0,1,2$ ) tais que (veja curva de separação  $L_2$  na figura 2.4(a)):

(0,1),(0,0),(1,1) produza  $z_2 = 1$   
(1,0) produza  $z_2 = 0$




Figura 4 - Realização da função OU-exclusivo

- a discussão acima mostra que existem pesos  $w_{ij}$  ( $i=1,2$ ;  $j=0,1,2$ ) de maneira que a entrada (0,1) resulte em  $z_1 = 1$ ,  $z_2 = 1$ , e a entrada (1,0) resulte em  $z_1 = 0$ ,  $z_2 = 0$ , enquanto que (0,0) e (1,1) produzam  $z_1 = 0$ ,  $z_2 = 1$ . Já que (0,0) e (1,1) podem ser separados linearmente de (0,1), como mostrado na figura 4(b) pela curva de separação  $L_3$ , pode-se concluir que a função booleana desejada pode ser obtida utilizando-se perceptrons em cascata, ou seja, um perceptron de três camadas.

- isto é possível devido à transformação do espaço de entrada  $(\mathbf{x}_1, \mathbf{x}_2)$ , onde os padrões não são linearmente separáveis, no espaço  $(\mathbf{z}_1, \mathbf{z}_2)$ , onde os padrões são linearmente separáveis.
- em reconhecimento de padrões é bem conhecido que quando classes de padrões podem ser separadas utilizando-se uma função discriminante não-linear, o problema pode ser transformado em um espaço de dimensão maior onde os padrões são linearmente separáveis.
- por exemplo, se a curva  $\mathbf{a}_0 + \mathbf{a}_1 \mathbf{u}_1 + \mathbf{a}_2 \mathbf{u}_2 + \mathbf{a}_3 \mathbf{u}_1 \mathbf{u}_2 = 0$  no espaço  $(\mathbf{u}_1, \mathbf{u}_2)$  separa duas classes de padrões, então um hiperplano (uma superfície linear) no espaço tridimensional  $(\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_1 \mathbf{u}_2)$  pode também separá-los. Esta foi a propriedade explorada na solução do problema do OU-exclusivo.
- obviamente, existem problemas de classificação muito mais “complexos” que o OU-exclusivo, não apenas por envolverem mais dimensões ou padrões, mas também por considerarem classes disjuntas.

## 2. Um problema mais geral de mapeamento não-linear

- considere, agora, um problema mais geral de classificação de padrões em um espaço de dimensão finita. Com base na figura 5, assume-se que a região triangular (conjunto **A**) corresponde a uma classe **1**, enquanto que o complemento desta região (conjunto **B**) corresponde a uma classe **2**. O objetivo é determinar os pesos de uma rede neural cuja saída é 1 (simbolizando a classe **1**) quando a entrada  $(\mathbf{x}_1, \mathbf{x}_2) \in \mathbf{A}$  e 0 (simbolizando a classe **2**) quando  $(\mathbf{x}_1, \mathbf{x}_2) \in \mathbf{B}$ .




Figura 5 - Um problema de reconhecimento de padrões

- partindo das conclusões extraídas da seção anterior, é possível afirmar que cada um dos três segmentos de reta que delimitam a região **A** pode ser representado por um neurônio tipo perceptron. Tomando-se a função booleana AND das saídas destes três perceptrons, a saída **y** pode ser feita **1** quando  $(\mathbf{x}_1, \mathbf{x}_2) \in \mathbf{A}$  e **0** quando  $(\mathbf{x}_1, \mathbf{x}_2) \in \mathbf{B}$ . A estrutura desta rede é apresentada na figura 6.




Figura 6 - Estrutura da rede para a solução do problema da figura 5

- a mesma abordagem pode ser estendida para casos onde o conjunto **A** é limitado por um polígono convexo. O número de neurônios necessários na primeira camada da rede é, neste caso, igual ao número de lados do polígono.
- se **A**<sub>1</sub>, **A**<sub>2</sub> e **A**<sub>3</sub> são conjuntos disjuntos (desconexos), cada qual limitado por um polígono convexo e o conjunto **A** = **A**<sub>1</sub> ∪ **A**<sub>2</sub> ∪ **A**<sub>3</sub> corresponde à classe **1** e o complemento de **A** (conjunto **B**) corresponde à classe **2**, a mesma abordagem descrita acima pode ser utilizada para reconhecer as duas classes. Neste caso, três redes idênticas àquela apresentada na figura 6 são utilizadas. As saídas **y**<sub>1</sub>, **y**<sub>2</sub> e **y**<sub>3</sub> das três redes são tomadas como entrada de uma função booleana OR, cuja saída é **1** (simbolizando classe **1**) quando  $(\mathbf{x}_1, \mathbf{x}_2) \in \mathbf{A}$  e **0** (simbolizando classe **2**) quando  $(\mathbf{x}_1, \mathbf{x}_2) \in \mathbf{B}$ .
- com base nos resultados obtidos acima, e levando-se em conta que as funções booleanas AND e OR podem ser executadas através de um único neurônio do tipo perceptron, conclui-se que um perceptron de quatro camadas pode executar a

tarefa de reconhecer elementos de conjuntos desconexos quando os conjuntos são limitados por segmentos lineares.

- situações mais gerais, onde as regiões não são convexas podem também ser adequadamente mapeadas utilizando-se um perceptron de três camadas, já que qualquer região não-convexa pode ser representada como uma união de regiões convexas.
- no entanto, a seleção automática dos pesos para redes com múltiplas camadas não é uma tarefa elementar. A principal dificuldade provém da natureza descontínua da função de ativação  $g$  utilizada (função sinal).
- uma solução para este problema será proposta quando for apresentado o algoritmo de treinamento para redes neurais multi-camadas, denominado algoritmo de retro-propagação, o qual requer que a função de ativação dos neurônios seja diferenciável, ao menos até 1ª ordem.

### **3. Mapeamentos não-lineares genéricos**

- na seção anterior, verificou-se que redes neurais de três camadas, compostas por unidades processadoras com função de ativação do tipo sinal, são capazes de realizar qualquer tipo de mapeamento não-linear que possa ser representado por uma seqüência de segmentos lineares.
- no entanto, muitos são os exemplos de mapeamentos não-lineares que não podem ser adequadamente descritos por seqüências de segmentos lineares e, portanto, não podem ser realizados por este tipo de rede neural.
- por exemplo, considere o problema de classificação de padrões pertencentes a duas classes distintas, separáveis por uma circunferência, conforme apresentado na figura 7.
- se for utilizada uma rede neural com função de ativação do tipo sinal, a melhor solução que pode ser obtida é uma aproximação da circunferência por trechos de segmento de reta.




Figura 7 - Padrões separáveis por uma circunferência

- a estrutura da rede neural é a mesma apresentada na figura 6, sendo que quanto maior o número de neurônios na primeira camada (camada de entrada), melhor será a aproximação. Esta relação é indesejável, pois cria uma dependência assintótica (com taxas de convergência muito baixas) entre a dimensão da rede e a capacidade de mapeamento.


- a conclusão que se pode extrair é que, no caso das redes neurais em camadas já apresentadas, funções de ativação lineares por partes, como é o caso da função sinal, vão conduzir a mapeamentos lineares por partes.
- portanto, existe aparentemente uma correspondência muito forte entre o tipo de não-linearidade da função de ativação e a capacidade de mapeamento de redes neurais artificiais para cada tipo de problema.
- se esta correspondência se aplicar a todos os tipos de função de ativação, fica bastante comprometida a utilização de redes neurais em problemas genéricos de mapeamento, pois passa a ser necessário conhecer exatamente a característica do mapeamento para que se possa definir a função de ativação a ser utilizada, ou seja, é preciso aplicar a solução do problema na composição da rede neural que, em princípio, iria solucionar o problema.
- felizmente, requisitos mínimos podem ser impostos às funções de ativação, de tal forma a garantir a existência de solução, independente do problema de aplicação.

- devido à estruturação da rede em camadas, o processamento dos sinais pela rede faz com que os sinais de saída sejam uma composição particular de funções de ativação, as quais devem atender a um conjunto mínimo de propriedades para conferir à rede neural o que se denomina de capacidade de aproximação universal de mapeamentos não-lineares contínuos, definidos em regiões compactas do espaço de aproximação.
- tomando por base métodos de aproximação universal para funções não-lineares, como séries de Taylor (composição de funções polinomiais) e séries de Fourier (composição de funções trigonométricas), não deve surpreender o fato de que redes neurais cujas funções de ativação são dotadas de algum tipo particular de não-linearidade sejam capazes de realizar qualquer tipo de mapeamento multidimensional entre os espaços de entrada e saída.

#### 4. Redes neurais multi-camadas e suas extensões

- nesta seção, vamos apresentar um exemplo ilustrativo de como é o processo de aproximação de mapeamentos não-lineares contínuos utilizando redes neurais multi-camadas (apresentaremos apenas o caso de uma camada intermediária), dotadas de função de ativação sigmoideal (portanto, uma função diferenciável).
- já vimos que diferentes expressões para a função de ativação sigmoideal  $g(\cdot)$  podem ser escolhidas.
- já vimos também que é recomendável que o(s) neurônio(s) da camada de saída tenham funções de ativação do tipo identidade. Neste caso, considerando  $p$  neurônios na única camada intermediária considerada, a função de transferência da rede neural pode ser dada na forma:  $y = c_0 + \sum_{n=1}^p c_n g(b_n x + a_n)$ , onde  $x$  é o vetor de entrada e  $y$  é a saída da rede.






$$y = c_0 + c_1 g(b_1 x + a_1) + c_2 g(b_2 x + a_2) \Rightarrow \begin{cases} a : \text{deslocamento no eixo } x \\ b : \text{inclinação da sigmóide} \\ c : \text{amplitude da sigmóide} \end{cases}$$

- isto significa que a rede neural com uma camada intermediária realiza um mapeamento que é dado por uma série truncada, tendo a função de ativação  $g(\cdot)$  como função básica (função-base).
- é possível então comparar este mapeamento com aquele realizado por uma série de Fourier truncada, dada na forma:  $y = c_0 + \sum_{n=1}^p c_n \cos(nw_0 x + a_n)$ .
- se tomarmos  $g(\cdot)$  como sendo  $\cos(\cdot)$ , deduz-se que a rede neural com uma camada intermediária se transforma em uma série de Fourier generalizada, pelo fato de permitir também o ajuste da frequência da função  $\cos(\cdot)$ .
- as frequências na série de Fourier são fixas (múltiplos da frequência fundamental  $w_0$ ) pois o ajuste deste termo representa uma operação não-linear, sem solução na forma fechada (requer processos iterativos de solução).
- como  $g(\cdot)$  pode assumir outras formas, além da função  $\cos(\cdot)$ , muitas outras possíveis extensões podem ser consideradas.

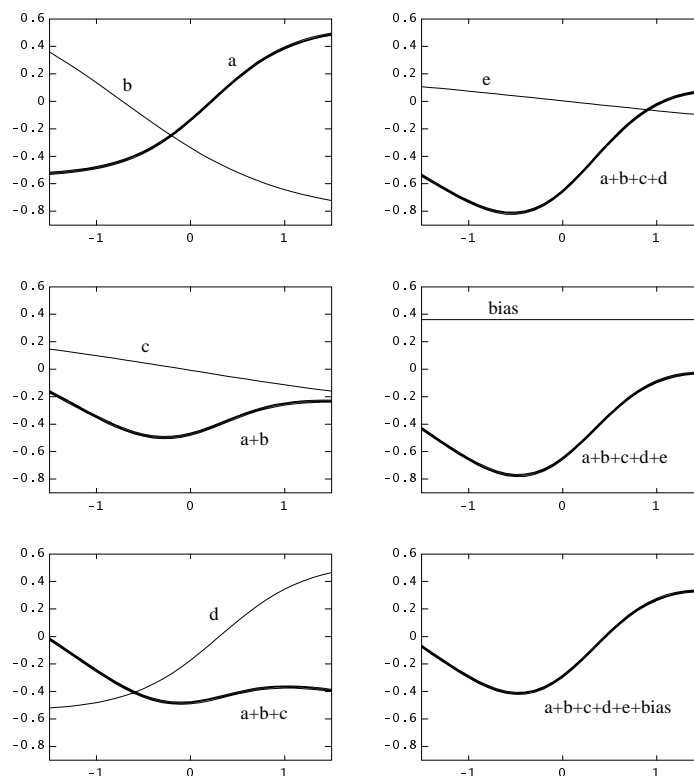
# Exemplo: Forma “construtiva” de aproximação de um mapeamento não-linear



$$f(\mathbf{w}) = \underbrace{c_1 g(b_1 x + a_1)}_a + \underbrace{c_2 g(b_2 x + a_2)}_b + \underbrace{c_3 g(b_3 x + a_3)}_c + \underbrace{c_4 g(b_4 x + a_4)}_d + \underbrace{c_5 g(b_5 x + a_5)}_e + \underbrace{c_0}_{\text{bias}}$$

Aulas 5 e 6

19



Aulas 5 e 6

20